

تشخیص بیماری ام اس با پردازش تصاویر MRI مغزی

نویسنده: زینب اعجازی، دکتری تخصصی، دانشگاه آزاد اسلامی، واحد تهران جنوب
مهدی اسلامی، دکتری تخصصی، دانشگاه آزاد اسلامی، واحد علوم و تحقیقات تهران

چکیده

بیماری ام اس MS بیماری است که سیستم اعصاب مرکزی را تحت تاثیر قرار می دهد. در نتیجه این بیماری مناطق متعدد اسکار بافتی به نام اسکلروز ممکن است ظاهر شود. تصویربرداری MRI یک معاینه اولیه مکمل برای نظارت و تشخیص مولتیپل اسکلروز MS است. شناسایی به موقع بیماری می تواند سرعت پیشرفت آن را کند کرده و یا متوقف کرد. امروزه روش های متنوعی برپا پیش بینی بیماری شناسایی شده است. در این مطالعه یک روش یادگیری ماشین پیشنهاد شده تا بتوان بیماری را با صحت بالا شناسایی کرد. برای این هدف، از ابزارهای پردازش تصویری مانند تبدیل موجک و ماتریس GLCM استفاده شده است. سپس از خروجی این ابزارها ویژگی های مختلفی نظیر انرژی، کنتراست، ضریب همبستگی، انتروپی و همگنی تصویر استخراج شده است. این ویژگی ها توسط سه طبقه بند SVM، KNN و درخت تصمیم گیری طبقه بندی شدند. روش مقاله مرجع یک روش ترکیبی بود که هم روش های یادگیری ماشینی و هم روش یادگیری عمیق را بررسی کرده بود. نتایج روش پیشنهادی نشان دهنده صحت بالای ۹۷٪ بود که به نسبت مقاله مرجع، بهبود حدود ۲ درصدی داشت.

کلمات کلیدی: ام اس، تبدیل ویولت، ماتریس GLCM، طبقه بند SVM، طبقه بندی KNN، طبقه بند درخت تصمیم گیری

۱- مقدمه:

ام اس یا مالتیپل اسکلروز^۱ به معنی اسکلروز متعدد یا زخم های چندگانه، یک بیماری خودایمنی مزمن و پیشرونده است که بر سیستم عصبی مرکزی تاثیر می گذارد [۱]. ام اس زمانی اتفاق می افتد که سیستم ایمنی به میلین حمله می کند. میلین، فیبرهای عصبی را در مغز و نخاع محافظت می کند. این اتفاق به عنوان میلین زدایی^۲ شناخته شده است و باعث می شود مشکل ارتباطی بین اعصاب و مغز پیش بیاید [۲]؛ یعنی میلین که روی عصب را گرفته از بین برود. در نهایت می تواند موجب آسیب اعصاب شود. این بیماری می تواند علائم مختلفی را برای بیمار ایجاد کند. در اکثر موارد، در ابتدا عوارض بیماری ام اس به تناوب ایجاد شده و بر طرف می شوند [۳، ۴]. با گذشت زمان، بعضی از این علائم، ماندگار شده و می توانند ناتوانی فرد را به همراه داشته باشند. هر چند هیچ درمان مشخصی برای این بیماری وجود ندارد، داروها و درمان بیماری ms به روش های مختلف می توانند تعداد دفعات عود بیماری و علائم و ناتوانی های مربوط به آن را کاهش دهند [۵]. بیماری ام اس درمان ندارد اما تشخیص به موقع و کنترل علائم آن سرعت پیشروی بیماری را کاهش می دهد [۶]. بنابراین تشخیص به موقع این بیماری بسیار مهم است. به دلیل عدم وجود متخصص در مناطق محروم، ممکن است بسیاری از بیماران در مراحل اولیه و قابل کنترل، متوجه بیماری نشوند. همین مسئله سبب می شود وجود سیستمی برای تشخیص به موقع بیماری حائز اهمیت شود [۷].

^۱ Multiple Sclerosis

^۲ demyelination

تشخیص ام اس توسط تصویربرداری توسط ام آر آی بهترین روش برای کمک به تشخیص این بیماری میباشد [۸]. از این روش برای پیگیری پیشرفت بیماری ام اس، تعیین وضعیت بیماری و عملکرد داروها می‌توان به طور مکرر استفاده نمود، اگرچه ممکن است پزشک از این روش به طور گسترده استفاده نکند. در ام آر آی از یک میدان مغناطیسی قدرتمند و امواج رادیویی تولید شده توسط رایانه برای اندازه گیری میزان آب در مناطقی از بدن مانند بافت ها، اعصاب، اندام ها و استخوان ها استفاده می شود و غیر تهاجمی ترین و حساس ترین روش موجود برای تصویربرداری از مغز نخاع و سایر نواحی بدن است [۹].

کارهای مختلفی برای شناسایی این بیماری انجام شده است. Tadayon و همکاران [۱۰] در سال ۲۰۱۶، یک الگوریتم KNN فازی (F-KNN) را برای دسته بندی ضایعات ام اس به سه نوع معرفی کرد. این طبقه بندی با ترکیب ویژگی های به دست آمده از تصاویر با کنتراست وزنی FLAIR، T-w1، T-w2، و T-w1 تقویت شده با گادولینیوم (Gad-E-T-w1) و ویژگی های استخراج شده اضافی از تصاویر DT-MR (نشر شاخص ها) شامل ناهمسانگردی کسری FA و انتشار میانگین MD، انجام شده است.

فولادی و همکاران [۱۱] در سال ۲۰۱۸، از نمونه های مختلف با ام اس عودکننده- فروکش کننده فرآیند طبقه بندی سه کلاسه بر اساس ANN را پیشنهاد داد. ویژگی های ورودی الگوریتم ANN که شامل سه نسخه MLP، RBF، و ENN بود، وابسته به معیار اطلاعات Akaike (ENN-AIC) به عنوان ایده آل های میانگین TI و QMT1 از نقشه های پارامتری استخراج شد. نتایج نشان داد که تکنیک مبتنی بر ENN-AIC، ۸۶٪ دقت، ۹۲٪ حساسیت و ۹۰٪ صحت را به دست آورده است که بهتر از سایر تکنیک های مختلف ANN مورد بررسی آن ها بود.

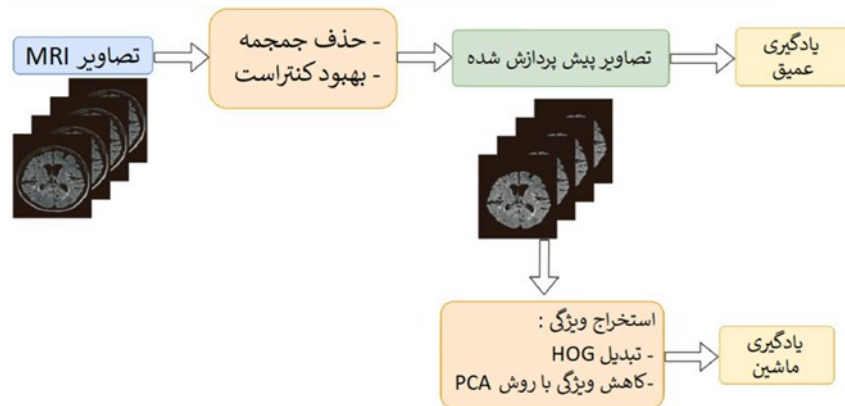
Jain و همکارانش [۱۲] در سال ۲۰۲۰، یک تکنیک طبقه بندی مبتنی بر یادگیری گروهی برای شناسایی بیماری های مولتیپل اسکلروزیس از پایگاه داده تصاویر رزونانس مغناطیسی مغز سالم و ناسالم (MR) پیشنهاد کردند. استخراج ویژگی از تصاویر MR مغز با استفاده از هجده ویژگی مختلف مبتنی بر ماتریس هم وقوع سطح خاکستری (GLCoM) انجام شده است. سپس، یادگیری گروهی مبتنی بر درخت تصمیم بر روی این ویژگی ها با استفاده از سه تکنیک تقویتی مختلف برای طبقه بندی تصویر MR انجام می شود. نتایج نشان داد که تکنیک یادگیری گروهی صحت بالای ۹۴.۹۱٪ را به همراه دارد.

Acar و همکاران [۱۳] در سال ۲۰۲۲، یک مدل CNN برای تشخیص MS از طریق تشخیص ضایعات در FLAIR MRI مغز ایجاد کردند. مجموعه داده مورد استفاده شامل MRI مغز، ماسک مغز و داده های حقیقت زمینه ۳۰ بیمار MS است که از آزمایشگاه فناوری های تصویربرداری (LabIT) به دست آمده است. ویژگی های ضایعات ام اس در MRI با مجموعه کوچکی از پارامترهای قابل آموزش استخراج می شوند. نتایج از تقسیم داده ها در سطح برش و همچنین در سطح بیمار تولید شد. با استفاده از تقسیم در سطح برش، مدل پیشنهادی به صحت 98.0 ± 0.02 درصد، حساسیت 97.9 ± 0.03 درصد، و ویژگی 98.3 ± 0.03 درصد و دقت 98.2 ± 0.03 درصد رسید. با استفاده از تقسیم در سطح بیمار، مدل پیشنهادی به دقت، حساسیت، و ویژگی و دقت به ترتیب 90.3 ± 0.05 ، 90.5 ± 0.05 ، 90.1 ± 0.09 درصد و 91.1 ± 0.09 درصد رسید.

در این پروژه، هدف ما تشخیص بیماری ام اس با کمک تصاویر MRI مغزی است. برای این منظور، ابتدا روی تصویر تبدیل موجک اعمال می شود. سپس ماتریس هم رخدادی (GLCM) از تصاویر محاسبه می شود. در مرحله بعد ویژگی های همگنی، کنتراست، آنترپی و انرژی از تبدیل موجک تصویر استخراج می شوند. سپس این ویژگی ها به شبکه عصبی داده شده و تصاویر دارای ضایعه تشخیص داده می شوند.

در مقاله مرجع [۱۳]، تصاویر ابتدا در یک فرآیند پیش پردازشی قرار می گیرد و جمعه از تصاویر آن حذف می شود. سپس با کمک هیستوگرام گرادیان های جهت دار^۳، از تصویر ویژگی استخراج می شود. سپس ویژگی های استخراج شده با کمک روش PCA کاهش پیدا میکند. در نهایت با کمک ۳ طبقه بند درخت تصمیم گیری، ماشین بردار پشتیبان و K نزدیک ترین همسایگی، طبقه بندی انجام می شود. علاوه بر این، یک مسیر مبتنی بر یادگیری عمیق نیز با شبکه های CNN اجرا شده است. شکل ۱، بلوک دیاگرام روش پیشنهادی را نمایش می دهد:

^۳ Histogram of Oriented Gradients




شکل ۱: بلوک دیاگرام کلی روش مقاله مرجع

۲- مواد و روش های

۲-۱- پیش پردازش


در مرحله پیش پردازش، ابتدا بر روی تمام داده های MRI، حذف جمجمه و کشش هیستوگرام برای بهبود کنتراست، اعمال شد. برداشتن جمجمه با کمک عملیات های مورفولوژیک بازکردن^۴ به کمک یک ماسک دایره ای به شعاع ۵ پیکسل، جمجمه حذف می شود. نتیجه این فرآیند در شکل ۲ نمایش داده شده است. پس از حذف جمجمه، نوبت به اصلاح هیستوگرام برای بهبود کنتراست است. از آنجایی که توزیع هیستوگرام تصاویر با یکدیگر متفاوت است، فرآیند یکواخت سازی هیستوگرام^۵ نتیجه بهبود کنتراست در شکل ۳ نمایش داده شده است.



شکل ۲: نتیجه حذف جمجمه از تصاویر MRI مغزی. سمت چپ تصویر اصلی و سمت راست تصویر پس از حذف جمجمه

^۴ imopening

^۵ Histogram Equalization




شکل ۳: نتیجه بهبود کنتراست تصویر MRI مغزی. سمت چپ تصویر اصلی و سمت راست تصویر پس از بهبود کنتراست

۲-۲- پردازش تصویر و استخراج ویژگی

همانطور که در ابتدای فصل بیان شد، این مطالعه شامل دو بخش است. در بخش اول، تصاویر پس از پیش پردازش، وارد شبکه های کانولوشنی از پیش آموزش دیده می شود تا با تکنیک یادگیری انتقالی، از تصاویر ویژگی استخراج شود. در بخش دوم، تصاویر به کمک الگوریتم هیستوگرام گرادیان های جهت دار، از تصاویر ویژگی استخراج می شود.

۲-۲-۱- استخراج ویژگی در روش پیشنهادی

تبدیل موجک^۶ یکی از تبدیلات مهم ریاضی است که در حوزه های مختلف علوم کاربرد دارد. ایده اصلی تبدیل موجک این است که بر ضعف ها و محدودیت های موجود در تبدیل فوری غلبه کند. این تبدیل را بر خلاف تبدیل فوری، می توان در مورد سیگنال های غیر ایستا و سیستم های دینامیک نیز مورد استفاده قرار داد [۱۴]. سیگنال از دو فیلتر عبور می کند، فیلترهای بالا گذر و فیلتر پایین گذر. سپس تصویر به اجزای فرکانس بالا (جزئیات) و فرکانس پایین (تقریبی) تجزیه می شود. در هر سطح، ۴ سیگنال فرعی دریافت می کنیم. تقریب روند کلی مقادیر پیکسل و جزئیات را به عنوان اجزای افقی، عمودی و مورب نشان می دهد. اگر این جزئیات ناچیز باشند، می توان آنها را بدون تأثیر قابل توجهی بر روی تصویر، صفر ارزیابی کرد و در نتیجه به فیلتر و فشرده سازی دست یافت [۱۵]. نتیجه اعمال تبدیل موجک بر روی یکی از تصاویر پایگاه داده در شکل ۳ مشاهده می شود:



شکل ۴: نمونه تصاویر پس از اعمال تبدیل موجک

^۶ Wavelet Transform

پس از اعمال تبدیل موجک، نوبت به استفاده از ماتریس های هم‌رخدادی سطح خاکستری^۷ می‌رسد. تئوری استفاده از ویژگی بافت با کمک ماتریس هم‌رخدادی سطح خاکستری یا به اختصار GLCM توسط Haralick در سال ۱۹۷۳ ارائه شد [۱۶]. ماتریس هر رخدادی سطح خاکستری یک روش آماری برای بررسی ویژگی های بافتی است که رابطه مکانی پیکسل ها را در نظر می‌گیرد. GLCM به عنوان ماتریس وابستگی فضایی خاکستری هم شناخته می‌شود. توابع GLCM بافت محاسبه یک تصویر را با محاسبه جابجایی جفت پیکسل با مقادیر خاص و در یک رابطه مشخص فضایی در یک تصویر ایجاد می‌کند. سایر فیلتر ها نمی‌توانند اطلاعاتی در خصوص قرار گیری پیکسل های مختلف در یک تصویر به ما بدهند. محاسبه GLCM تصویر و سپس استخراج معیارهای آماری از این ماتریس می‌تواند ویژگی هایی را برای طبقه بندی و یا بافت شناسی تصویر مشخص کند که به خوبی قابل تشخیص باشند [۱۷]. برای ایجاد GLCM، از تابع graycomatrix استفاده می‌شود. این تابع یک ماتریس هم‌رخدادی سطح خاکستری (GLCM) را با محاسبه اینکه چند پیکسل با مقدار شدت روشنایی (سطح خاکستری) i در یک رابطه خاص فضایی با یک پیکسل با مقدار شدت روشنایی (سطح خاکستری) j قرار می‌گیرد، ایجاد می‌کند. به طور پیش فرض، روابط فضایی به عنوان پیکسل مورد علاقه و پیکسل به سمت راست آن (افقی مجاور) تعریف می‌شود، اما شما می‌توانید سایر روابط فضایی بین دو پیکسل را مشخص کنید. هر عنصر (i, j) در ماتریس glcm به سادگی مجموع تعداد دفعاتی است که پیکسل با مقدار i در رابطه مکانی مشخص شده با پیکسل با مقدار j در تصویر ورودی رخ داده است.

پس از محاسبه این دو تبدیل، نوبت به استخراج ویژگی می‌رسد. استخراج ویژگی فرایندی است که در آن با انجام عملیاتی بر روی داده‌ها، ویژگی‌های بارز و تعیین‌کننده آن مشخص می‌شود. هدف استخراج ویژگی این است که داده‌های خام به شکل قابل استفاده‌تری برای پردازش‌های آماری بعدی درآیند. ویژگی های آماری به دست آمده از GLCM، به عنوان یک ساختار با فیلدهایی که توسط ویژگی ها مشخص شده اند، قابل محاسبه می‌باشند. در این پروژه ما ۴ دسته ویژگی آماری قابل استنتاج از این ماتریس داریم.

کنتراست تفاوت درخشندگی رنگ یا تضاد در پیکسل های تصویر است که باعث تمایز آنها (یا تصویرشان) از یکدیگر می‌شود. واژه فرانسوی کنتراست به معنای تباین و جدایی است و یکی از اصل‌های پایه‌ای رشته‌های گوناگون هنر است. برای محاسبه کنتراست، ابتدا لازم است ماتریس GLCM را محاسبه کنیم. پس از محاسبه این ماتریس، کنتراست از رابطه ۱ محاسبه می‌شود [۱۸]:

$$Contrast = \sum_{i,j} |i - j|^2 C(i, j) \quad \text{رابطه ۱}$$

که متغیر C در آن، ماتریس GLCM تصویر است. با توجه به اینکه آفست های متنوعی برای محاسبه ماتریس GLCM استفاده کردیم، به ازای هر ماتریس، یک مقدار برای کنتراست بدست خواهد آمد.

ضریب همبستگی ابزاری آماری برای تعیین نوع و درجه رابطه یک متغیر کمی با متغیر کمی دیگر است. ضریب همبستگی، یکی از معیارهای مورد استفاده در تعیین همبستگی دو متغیر است. ضریب همبستگی شدت رابطه و همچنین نوع رابطه (مستقیم یا معکوس) را نشان می‌دهد. این ضریب بین ۱ تا -۱ است و در صورت عدم وجود رابطه بین دو متغیر، برابر صفر است [۱۸]. همبستگی بین دو متغیر تصادفی X و Y به صورت رابطه زیر تعریف می‌شود:

$$corr(X, Y) = \frac{cov(X, Y)}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y} \quad \text{رابطه ۲}$$

که در آن E عملگر امید ریاضی، cov به معنای کوواریانس، $corr$ نماد معمول برای همبستگی پیرسون، و سیگما نماد انحراف معیار است. انرژی و توان دارای تعاریف متفاوتی نسبت به تعریف انرژی و توان در فیزیک هستند. در فیزیک، انرژی برابر با کار و

^۷ Gray Level Co-Occurrence Matrix

توان برابر با کار در واحد زمان تعریف می‌شود. اما در علم پردازش تصویر، انرژی و توان تصویر بدون واحد فیزیکی در نظر گرفته می‌شوند؛ زیرا پیکسل‌های تصویر ممکن است نشان‌دهنده کمیت‌های فیزیکی مختلفی باشند. می‌توان گفت انرژی و توان سیگنال را بر اساس اندازه سیگنال به دست می‌آورند [۱۸]. برای محاسبه انرژی تصویر از روی ماتریس GLCM، کافی است تمامی مقادیر این ماتریس را به توان دوم رسانده و سپس آن‌ها را با هم جمع کنیم:

$$Energy = \sum_{i,j} |C(i,j)|^2 \quad \text{رابطه ۳}$$

توزیع مقادیر مختلف شدت روشنایی در یک تصویر را می‌توان با یک عامل همگن تعیین کرد. به طور کلی، یک تصویر همگن است اگر هر نقطه (پیکسل) در تصویر دارای رنگ یکسان باشد. اگر تضادهای قوی در یک تصویر وجود داشته باشد، ناهمگن است. از نظر آماری، در ساده‌ترین حالت، انحراف استاندارد هر پیکسل از میانگین مقدار خاکستری قابل محاسبه است. اگر واریانس این انحراف معیار زیاد باشد، همگنی پایین است [۱۸]. برای محاسبه این پارامتر، از رابطه زیر استفاده می‌کنیم:

$$Homogeneity = \sum_{i,j} \frac{C(i,j)}{1 + |i - j|} \quad \text{رابطه ۴}$$

۲-۲-۲- استخراج ویژگی در مقاله مرجع

هیستوگرام گرادیان‌های گرا^۸ (HOG) یک توصیفگر ویژگی است که در بینایی کامپیوتری و پردازش تصویر به منظور تشخیص اشیاء استفاده می‌شود. این تکنیک، جهت‌گیری گرادیان را در بخش‌های محلی یک تصویر شمارش می‌کند. این روش شبیه هیستوگرام‌های جهت‌گیری لبه، توصیف‌گرهای تبدیل ویژگی تغییرناپذیر مقیاس، و زمینه‌های شکل است، اما از این جهت متفاوت است که بر روی شبکه‌ای متراکم از سلول‌های با فاصله یکنواخت محاسبه می‌شود و از نرمال‌سازی کنتراست محلی همپوشانی برای بهبود دقت استفاده می‌کند [۱۹].

دالال و تریگز چهار روش مختلف را برای نرمال‌سازی بلوک بررسی کردند. اگر v بردار غیر نرمال شده حاوی تمام هیستوگرام‌ها در یک بلوک معین باشد، $\|v\|_k - norm$ ای آن باشد $k=1,2$ و e مقداری ثابت کوچک باشد. سپس ضریب عادی‌سازی می‌تواند یکی از موارد زیر باشد [۲۰]:

$$\begin{aligned} L2 - norm : \quad f &= \frac{v}{\sqrt{\|v\|_2^2 + e^2}} \\ L1 - norm : \quad f &= \frac{v}{(\|v\|_1 + e)} \\ L1 - sqrt : \quad f &= \sqrt{\frac{v}{(\|v\|_1 + e)}} \end{aligned} \quad \text{رابطه ۲}$$

دالال و تریگز در آزمایش‌های خود دریافتند که طرح‌های L^2 -norm و L^1 -sqrt عملکرد مشابهی را ارائه می‌دهند، در حالی که L^1 -norm کمی کمتر قابل اعتماد را ارائه می‌دهد. با این حال، هر سه روش بهبود بسیار قابل توجهی را نسبت به داده‌های غیرعادی نشان دادند. در این مطالعه از L^2 -norm برای استخراج ویژگی استفاده می‌شود.

پس از استخراج ویژگی در این روش، نوبت به کاهش ویژگی با روش PCA می‌رسد. این روش اصلی‌ترین روش خطی برای کاهش ابعاد است؛ این روش نگاشت خطی داده‌ها را به یک فضا با بعد پایین‌تر انجام می‌دهد، به طوری که میزان توضیح واریانس داده اصلی در داده منتقل شده (به ابعاد کمتر) بیشینه باشد. در عمل، ماتریس واریانس (و بعضی اوقات کوواریانس) داده‌ها ساخته


^۸ Histogram of Gradient

می‌شود و بردار ویژه این ماتریس محاسبه می‌شود. بردار ویژه‌هایی که متناظر با بزرگ‌ترین مقادیر ویژه‌ها هستند، بیش‌ترین میزان اطلاعات از داده‌های اصلی را در خود دارند و اکنون می‌توانند برای بازسازی بخش بزرگی از واریانس داده‌های اصلی استفاده شوند. به صورت تخمینی، چندین بردار اول را می‌توان نماینده رفتار کلان داده تفسیر کرد. داده در ابعاد کمتر با استفاده از این بردارهای اصلی همراه با از دست دادن بخشی از اطلاعات (با این امید که توضیح دهنده‌گی واریانس را تا حد خوبی حفظ کند) ساخته می‌شود. پس از کاهش ویژگی، تعداد ویژگی‌ها را به عدد ۱۰ می‌رسانیم.

مرحله بعدی، طبقه‌بندی است. طبقه‌بندی مسئله شناسایی تعلق یک مشاهده جدید به کدام یک از مجموعه دسته‌ها (زیر-جمعیت‌ها)، بر اساس یک مجموعه از داده‌های مورد استفاده به منظور آموزش شامل مشاهدات است که عضویت در دسته‌هایشان معلوم است [۲۱]. در اصطلاح یادگیری ماشین، طبقه‌بندی نوعی یادگیری با نظارت است، که مجموعه‌ای داده‌ها برای آموزش موجودند. در این مطالعه از ۳ طبقه بند ماشین بردار پشتیبان، k نزدیک ترین همسایگی و درخت تصمیم‌گیری استفاده شده است. مبنای کاری دسته‌بندی کننده SVM دسته‌بندی خطی داده‌ها است و در تقسیم خطی داده‌ها سعی می‌کنیم ابرصفحه‌ای را انتخاب کنیم که حاشیه اطمینان بیشتری داشته باشد. الگوریتم K نزدیک ترین همسایه یا KNN یکی از ساده‌ترین الگوریتم‌های یادگیری ماشین است. این الگوریتم برای مسائل طبقه‌بندی k نزدیک ترین همسایه را پیدا و با اکثریت آرا نزدیک‌ترین همسایگان کلاس را پیش‌بینی می‌کند. درخت‌های تصمیم به گروه الگوریتم‌های یادگیری تحت نظارت تعلق دارند و بیشتر آنها بر اساس حداقل‌سازی کمیتی به نام آنتروپی ساخته می‌شوند.

۳- مجموع داده‌ها

مجموعه داده‌های مطالعه، شامل تصاویر MRI FLAIR محوری و ساژیتال از مغز بود که از ۷۲ بیمار مبتلا به MS و ۵۹ فرد سالم مرد و زن غیر بیمار که در سال ۲۰۲۱ در دانشکده پزشکی دانشگاه اوزال حضور داشتند، به دست آمد. کمیته اخلاق سازمانی این مطالعه را تأیید کرده بود. کارشناسان پزشکی بخش‌های تصویر FLAIR را می‌خوانند. از ۷۲ بیمار MS، ۱۴۴۱ بخش تصویر مغز محوری و ساژیتال حاوی ضایعات MS قابل شناسایی به کلاس MS اختصاص داده شد. از ۵۹ فرد سالم نیز ۲۰۱۶ برش‌های تصویر محوری و ساژیتال با ظاهر طبیعی، یعنی بدون به طبقه سالم اختصاص داده شد. نمونه تصاویر موجود در پایگاه داده در شکل ۵ نمایش داده شده است [۲۲].



شکل ۵: نمونه تصاویر پایگاه داده مورد استفاده [۲۲]

۴- نتایج

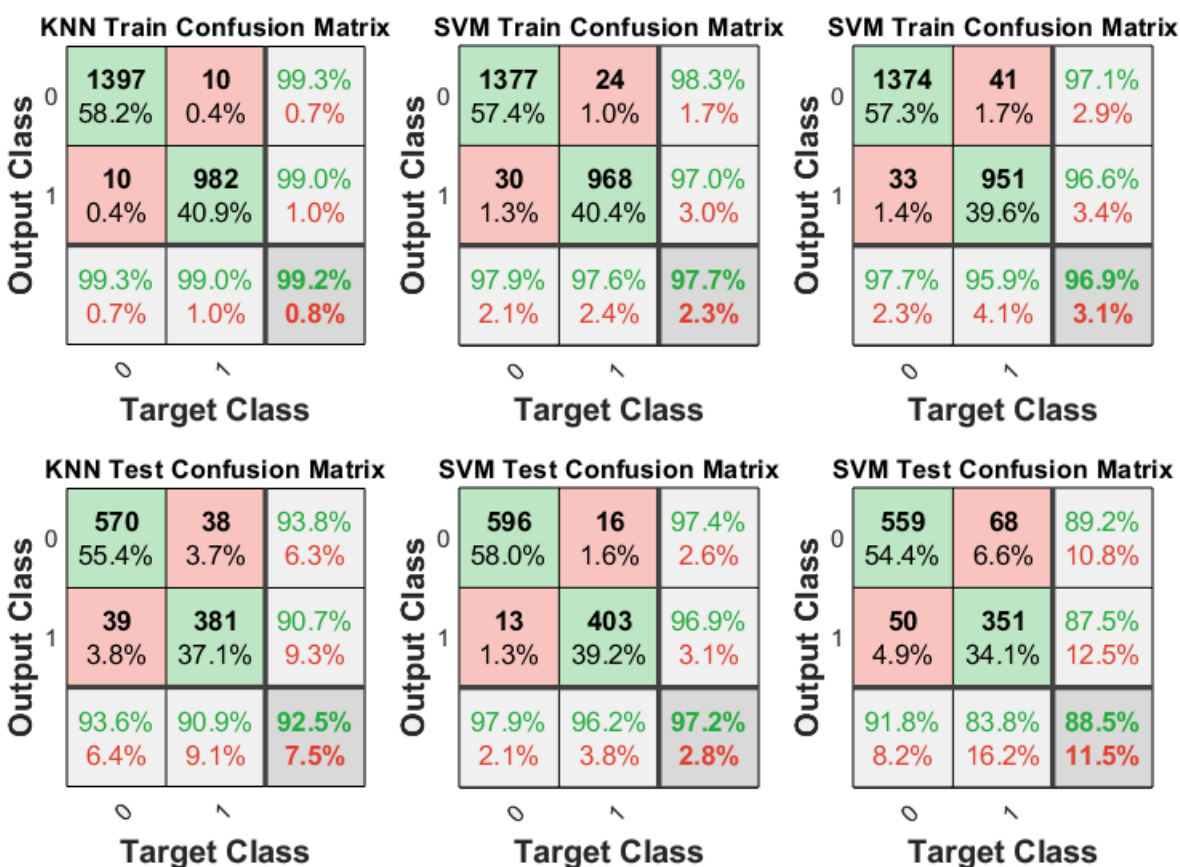
در بحث یادگیری ماشین، مطالعه و ساخت الگوریتم‌هایی که می‌تواند بر اساس مجموعه داده، یادگیری و پیش‌گیری کند، مرسوم است. این الگوریتم‌ها از طریق پیش‌بینی یا تصمیم‌گیری مبتنی بر داده، از طریق ساختن یک مدل ریاضی بر اساس داده‌های ورودی عمل می‌کنند. داده‌های مورد استفاده برای ساخت مدل نهایی معمولاً از مجموعه داده‌های متعدد تهیه می‌شود.

به‌طور خاص، معمولاً از ۲ مجموعه داده در مراحل مختلف ایجاد مدل، استفاده می‌شود. این مدل در ابتدا بر روی یک مجموعه داده آموزشی ساخته می‌شود، تا یا استفاده از مجموعه ای از مثال ها، توانایی متناسب کردن پارامترهای مدل فراهم شود. مجموعه داده آزمایشی مجموعه داده‌ای است که برای ارائه ارزیابی بی طرفانه از مدل نهایی متناسب با مجموعه داده های آموزشی استفاده می‌شود. در این پروژه نیز داده ها به ۲ دسته داده های آموزش و داده های آزمون تقسیم بندی شدند که معیارهای ارزیابی بیان شده، برای هر کدام از دو حالت فوق، و همچنین کل داده های مورد ارزیابی محاسبه شد که در جدول ۱، نتایج طبقه بندی با استفاده از روش پیشنهادی گزارش شده است:

جدول ۱: نتایج طبقه بندی با روش پیشنهادی

	Train			Test		
	KNN	SVM	DT	KNN	SVM	DT
Accuracy	99.166	97.749	96.915	92.51	97.179	88.521
Sensitivity	99.289	97.868	97.655	93.596	97.865	91.79
Specificity	98.992	97.581	95.867	90.931	96.181	83.771
Precision	99.289	98.287	97.102	93.75	97.386	89.155
F1-Score	99.289	98.077	97.378	93.673	97.625	90.453

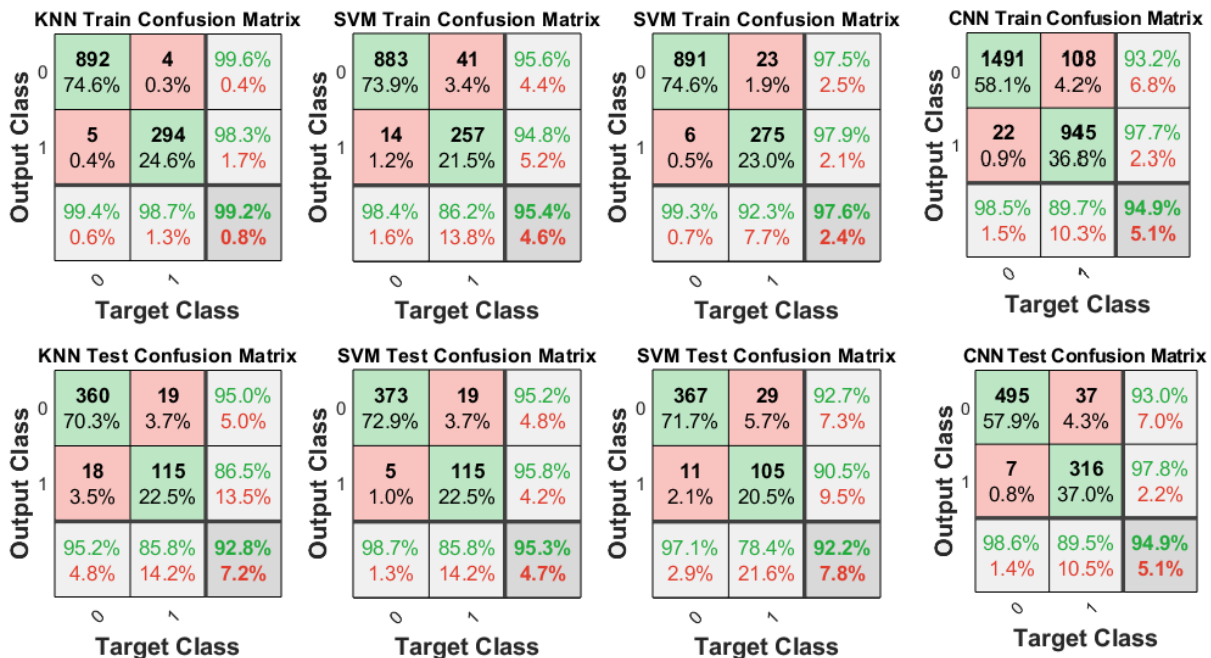
شکل ۶: ماتریس در هم‌ریختگی روش پیشنهادی



جدول ۲: نتایج طبقه بندی با روش دوم برای مقایسه با مقاله مرجع [۱۳]

	Train				Test			
	KNN	SVM	DT	CNN	KNN	SVM	DT	CNN
Accuracy	99.247	95.397	97.573	94.934	92.773	95.313	92.188	94.854
Sensitivity	99.443	98.439	99.331	98.546	95.238	98.677	97.09	98.606
Specificity	98.658	86.242	92.282	89.744	85.821	85.821	78.358	89.518
Precision	99.554	95.563	97.484	93.246	94.987	95.153	92.677	93.045
F1-Score	99.498	96.98	98.399	95.823	95.112	96.883	94.832	95.745

شکل ۷: ماتریس در هم‌ریختگی روش مقاله مرجع



۵- جمع بندی

در این مطالعه، ما بر اساس این تصاویر و برجسب های اختصاص داده شده توسط پزشک متخصص، سعی در یافتن یک طبقه بند با دقت مناسب بودیم. ما از تصاویر MRI مغزی بر اساس داده های مجموعه Kaggle استفاده کردیم. در ادامه روند این پروژه، ابتدا یک مرحله پیش پردازش برای حذف جمجه و بهبود کنتراست اعمال می شود. سپس با کمک تبدیل ویولت و ماتریس GLCM به استخراج ویژگی از تصاویر پرداختیم. ۴ ویژگی انرژی، کنتراست، همگنی و ضریب همبستگی برای این منظور استخراج شد. پس از استخراج ویژگی، این ویژگی ها به کمک طبقه بندهای KNN، SVM و درخت همسایگی طبقه بندی می شوند. برای مقایسه با مقاله مرجع، روش دومی نیز اعمال شد. در این روش پس از پیش پردازش، با کمک تبدیل هیستوگرام گرادیان های جهت دار، ویژگی هایی از تصویر استخراج شده و سپس به کمک روش PCA، ویژگی های بهینه انتخاب می شود. نتایج نشان می دهد که روش پیشنهادی بالاترین عملکرد را با صحت ۹۷.۲٪ در فاز آزمون با شبکه SVM بدست آورده است. از سوی دیگر، استفاده از الگوریتم اعتبارسنجی ۱۰ برابر در الگوریتم پیشنهادی کمترین خطا را در مقایسه با استفاده از شبکه ها به طور مستقل نشان می دهد.

- [١] Klineova, Sylvia, and Fred D. Lublin. "Clinical course of multiple sclerosis." Cold Spring Harbor perspectives in medicine ٨,٩ (٢٠١٨): a٠٢٨٩٢٨.
- [٢] Filippi, Massimo, et al. "Pediatric Multiple Sclerosis." White Matter Diseases: An Update for Neurologists (٢٠٢٠): ٢٧-٦٦.
- [٣] Thru, C., et al. "Time matters: early-phase multiple sclerosis is accompanied by considerable impairments across multiple domains." Multiple Sclerosis Journal ٢٧,١٠ (٢٠٢١): ١٤٧٧-١٤٨٥.
- [٤] Baroncini, Damiano, et al. "Risk of persistent disability in patients with pediatric-onset multiple sclerosis." JAMA neurology ٧٨,٦ (٢٠٢١): ٧٢٦-٧٣٥.
- [٥] Simonsen, Cecilia Smith, et al. "Early high efficacy treatment in multiple sclerosis is the best predictor of future disease activity over ١ and ٢ years in a Norwegian population-based registry." Frontiers in Neurology ١٢ (٢٠٢١): ٦٩٣٠١٧.
- [٦] Jain S, Rajpal N, Yadav J. Multiple Sclerosis Identification Based on Ensemble Machine Learning Technique. In Proceedings of the ٢nd International Conference on IoT, Social, Mobile, Analytics & Cloud in Computational Vision & Bio-Engineering (ISMAC-CVB ٢٠٢٠) ٢٠٢٠ Nov ٢١.
- [٧] Macin G, Tasci B, Tasci I, Faust O, Barua PD, Dogan S, Tuncer T, Tan RS, Acharya UR. An accurate multiple sclerosis detection model based on exemplar multiple parameters local phase quantization: ExMPLPQ. Applied Sciences. ٢٠٢٢ May ١٢;١٢(١٠):٤٩٢٠.
- [٨] Caverly, Robert H. "MRI fundamentals: RF aspects of magnetic resonance imaging (MRI)." IEEE Microwave Magazine ١٦,٦ (٢٠١٥): ٢٠-٣٣.
- [٩] Khashami, Fatemeh. Fundamentals of NMR and MRI: From Quantum Principles to Medical Applications. Springer Nature, ٢٠٢٢.
- [١٠] Tadayon E, Khayati RM, Karami V, Nabavi SM. A novel method for automatic classification of multiple sclerosis lesion subtypes using diffusion tensor MR images. Biomedical Engineering: Applications, Basis and Communications. ٢٠١٦ Oct ٣١;٢٨(٠٥):١٦٥٠٠٣٨.
- [١١] Fooladi M, Sharini H, Masjoodi S, Khodamoradi E. A novel classification method using effective neural network and quantitative magnetization transfer imaging of brain white matter in relapsing remitting multiple sclerosis. Journal of biomedical physics & engineering. ٢٠١٨ Dec;٨(٤):٤٠٩.
- [١٢] Jain S, Rajpal N, Yadav J. Multiple Sclerosis Identification Based on Ensemble Machine Learning Technique. In Proceedings of the ٢nd International Conference on IoT, Social, Mobile, Analytics & Cloud in Computational Vision & Bio-Engineering (ISMAC-CVB ٢٠٢٠) ٢٠٢٠ Nov ٢١.
- [١٣] Acar ZY, Başçiftçi F, Ekmekci AH. A Convolutional Neural Network model for identifying Multiple Sclerosis on brain FLAIR MRI. Sustainable Computing: Informatics and Systems. ٢٠٢٢ Sep ١;٣٥:١٠٠٧٠٦.

- [١٤] Mourad, Talbi. "Wavelets and wavelet transforms." ECG Denoising Based on Total Variation Denoising and Wavelets. Cham: Springer International Publishing, ٢٠٢٣. ١-١٨.
- [١٥] Wang, Jizeng, Xiaojing Liu, and Youhe Zhou. "Application of wavelet methods in computational physics." Annalen der Physik ٥٣٦,٥ (٢٠٢٤): ٢٣٠٠-٤٦١.
- [١٦] Zubair, Abdul Rasak, and Oluwaseun Adewunmi Alo. "Grey level co-occurrence matrix (GLCM) based second order statistics for image texture analysis." arXiv preprint arXiv:٢٤٠٣,٠٤٠٣٨ (٢٠٢٤).
- [١٧] Pantic, Igor, et al. "Gray level Co-occurrence matrix, fractal and wavelet analyses of discrete changes in cell nuclear structure following osmotic stress: Focus on machine learning methods." Fractal and Fractional ٧,٣ (٢٠٢٣): ٢٧٢.
- [١٨] Yunianto, Mohtar, et al. "Gray Level Co-Occurrence Matrices and Support Vector Machine for Improved Lung Cancer Detection." International Journal of Online & Biomedical Engineering ١٩,٥ (٢٠٢٣).
- [١٩] Patel, Chirag I., et al. "Histogram of oriented gradient-based fusion of features for human action recognition in action video sequences." Sensors ٢٠,٢٤ (٢٠٢٠): ٧٢٩٩.
- [٢٠] Zhou, Wei, et al. "Histogram of oriented gradients feature extraction from raw bayer pattern images." IEEE Transactions on Circuits and Systems II: Express Briefs ٦٧,٥ (٢٠٢٠): ٩٤٦-٩٥٠.
- [٢١] Uddin, Md Palash, Md Al Mamun, and Md Ali Hossain. "PCA-based feature reduction for hyperspectral remote sensing image classification." IETE Technical Review ٣٨,٤ (٢٠٢١): ٣٧٧-٣٩٦.
- [٢٢] Macin, Gulay, et al. "An accurate multiple sclerosis detection model based on exemplar multiple parameters local phase quantization: ExMPLPQ." Applied Sciences ١٢,١٠ (٢٠٢٢): ٤٩٢٠.